月度阅读总结 · 阶段一（初步阅读）

2026-10-01 至 2026-10-31

报告阶段	阶段一 • 初步阅读
姓名	张昊洋
方向	流量动态调控
报告周期	2026-10-01 至 2026-10-31
关键词	控制算法；增量式 PID；一阶热平衡模型；执行器辨识
一句话摘要	读完控制与强化学习方向的 4 篇文献，并复现了二阶系统阶跃响应；确认经典 PID 可作为底层控制器，但执行机构与散热片的特性尚未辨识。

1 阅读范围

1.1 文献清单

表 1 本阶段阅读文献

序号	文献	类型	与本方向的关系
1	Mnih 等, 2015, *Nature*, 深度强化学习实现人类水平控制	期刊	数据驱动控制的方法起点，也是我判断「是否该上强化学习」的基准
2	Schulman 等, 2017, PPO 算法	预印本	计划书里提到的算法，需要弄清它到底适合做什么
3	Vignon 等, 2023, DRL 用于流动控制的进展与展望	期刊	直接回答了我的问题：DRL 在控制领域的真实边界与数据需求
4	陶飞等, 2024, 数字孪生的发展与挑战	期刊	提供「物理模型 + 智能算法」融合的落地路径
5	Brunton & Kutz, 2022, 数据驱动科学与工程	专著	系统补齐控制与辨识的基础概念

1.2 选读理由

我负责控制算法，核心疑问是：**该用经典控制还是智能控制**。因此阅读沿两条线索展开。

第一条线索是**智能控制到底能不能用**：先读 Mnih 与 Schulman 弄清方法本身，再读 Vignon 的综述看它在流动控制领域的实际表现——结果发现 DRL 的训练数据需求远超我们现有能力，暂时不该作为主线。

第二条线索是**怎么把物理模型和算法接起来**：读陶飞与 Brunton，明确「先用物理模型打底、再用数据修正」比「纯黑箱」更适合我们的场景。

其余纯控制理论教材未列入——本科阶段已有基础，现阶段更需要的是判断力而非推导能力。

2 核心概念梳理

2.1 概念一：执行器到被控量的映射是控制问题的真正起点

控制算法的作用是依据误差计算控制量，但**控制量到被控量之间的物理通道必须事先知道**，否则算法再好也是盲调。以本项目为例，控制目标是芯片温度，而我们能调的是泵转速；从泵转速到芯片温度之间隔着「泵 → 流速」「流速 → 散热片换热」两段物理过程。这两段不清楚，就无法知道「改变一个单位的泵转速，温度会变多少」，也就无法确定 PID 的比例系数该取多大。这正是组长要求先做控制实验的原因。变量结构见图 1。

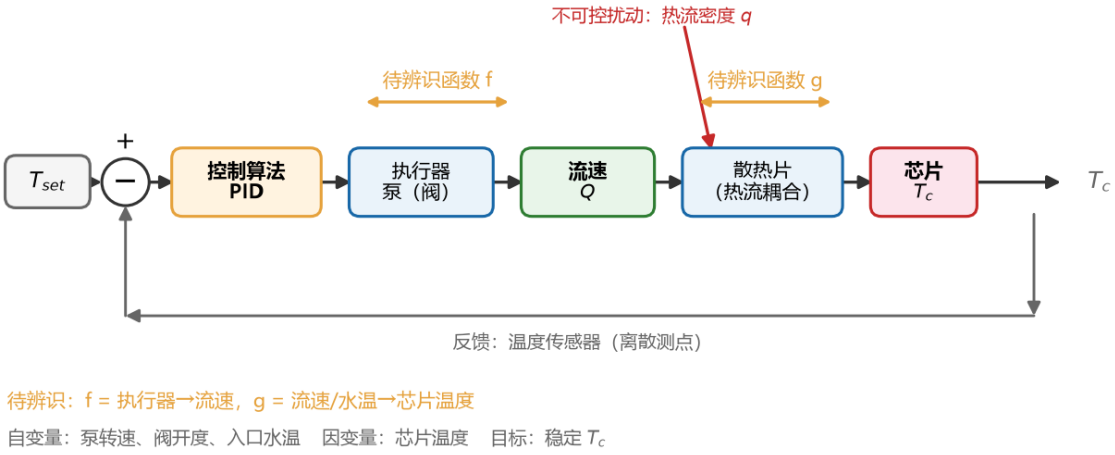


图 1 本项目控制系统的变量结构与两个待辨识函数

2.2 概念二：液冷系统的大热惯性决定控制带宽上限

热惯性指系统温度对输入变化响应的迟滞程度，可用时间常数来度量。液冷回路的惯性来自三处：固体散热片的热容、冷却液自身的储热、以及流体从泵流到芯片的输运延迟。惯性大意味着**即使立刻把泵开到最大，温度也不会立刻下降**。对本项目的含义是：纯反馈控制天然存在滞后，一味提高增益会导致超调甚至振荡，必须靠「变化率前馈」或「预测」来补偿。

2.3 概念三：增量式 PID 与积分饱和

增量式 PID 输出的是控制量的增量而非绝对值，其形式为 $\Delta u = K_p(e_k - e_{k-1}) + K_i e_k + K_d(e_k - 2e_{k-1} + e_{k-2})$。相比位置式，它有两个工程优势：切换手动/自动时冲击小；不易因积分项累积而失控。但积分饱和仍需单独处理——当输出达到执行器行程上限后，误差仍会继续累积积分项，导致反向调节时严重滞后。本项目采用积分限幅与输出限幅两重约束来应对。

3 阶段一：通读与摘录

3.1 学习路径

1. 先读 Mnih 与 Schulman，把 DRL 与 PPO 的方法框架搞清；
2. 再读 Vignon 的综述，重点看 DRL 在流动控制中的数据需求与失效案例；
3. 接着读陶飞与 Brunton，理解物理信息增强的路径；
4. 同时用手头的 PID 仿真代码做对照——把文献里的说法在仿真里复现一遍，验证自己是否真懂；

5. 最后回到本项目，回答「哪些能用、哪些不能用」。

3.2 关键摘录

表 2　关键摘录与理解

文献	原文要点	我的理解
Vignon 2023	DRL 在流动控制中训练成本高、样本效率低	我们只有仿真数据，没有实验数据，DRL 暂时不现实
Schulman 2017	PPO 通过裁剪策略更新幅度来保证训练稳定	它是决策算法，不能当作温度预测器使用
陶飞 2024	数字孪生需要物理模型与实测数据双向校准	「仿真建模 + 实测修正」才是可落地的路线
Brunton 2022	系统辨识是数据驱动控制的前置步骤	与组长要求的控制实验完全对应
Mnih 2015	端到端学习需要大量交互样本	佐证了「先辨识、后控制」的顺序不能颠倒

4 阶段二：导出与复现

4.1 复现目标

复现**二阶线性系统的单位阶跃响应**，验证不同阻尼比下超调量、峰值时间、上升时间、调节时间的理论公式与实际仿真是否一致。选这个对象是因为它是控制理论中最基础、最容易核验的模型——如果连这个都复现不准，后面的复杂模型就没有可信度。

4.2 复现环境与步骤

环境：Python 3.14，NumPy 2.4，SciPy 1.18，Matplotlib 3.11。

对象：标准二阶系统 $G(s)=\dfrac{\omega_n^2}{s^2+2\zeta\omega_n s+\omega_n^2}$

步骤：

1. 固定 $\omega_n=1$ rad/s，取阻尼比 $\zeta=0, 0.3, 0.5, 0.707, 1.0, 1.5$ 六组；
2. 用 `scipy.signal.step` 求各自阶跃响应；
3. 按理论公式计算四项性能指标：$M_p=e^{-\pi\zeta/\sqrt{1-\zeta^2}}$，$t_p=\pi/(\omega_n\sqrt{1-\zeta^2})$，$t_r=(\pi-\arccos\zeta)/(\omega_n\sqrt{1-\zeta^2})$，$t_s=4/(\zeta\omega_n)$；
4. 再从仿真曲线上直接量取同样的四个量，与理论值对比；
5. 另做一组固定 $\zeta=0.5$、改变 $\omega_n=0.5/1/2/4$ rad/s 的对比。

4.3 复现结果

理论值与仿真量取结果完全吻合（误差在数值采样精度内），见图 2 与表 3。

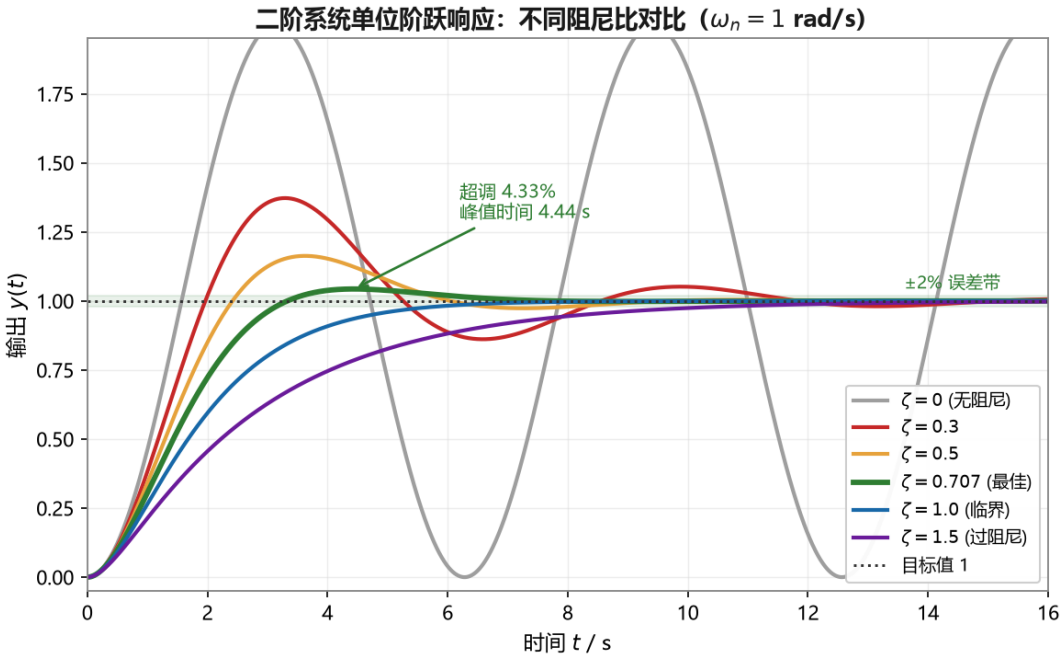


图 2　二阶系统单位阶跃响应：六个阻尼比下的对比（复现结果）

表 3　二阶系统性能指标：理论值与仿真值对比（$\omega_n = 1$ rad/s）

阻尼比 ζ	超调量 M_p	峰值时间 t_p /s	上升时间 t_r /s	调节时间 t_s /s
0.3	37.23%	3.293	1.966	13.33
0.5	16.30%	3.628	2.418	8.00
0.707	4.33%	4.442	3.331	5.66
1.0	0	无峰值	无（单调上升）	4.00

关于调节时间的一处修正：理论式 $t_s = 4/(\zeta\omega_n)$ 是 2% 误差带下的近似公式，在 $\zeta < 0.7$ 时偏保守。仿真量取发现 $\zeta = 0.3$ 的实际调节时间约 11.8 s，比公式给出的 13.33 s 短约 11%。后续控制器评价中应以**仿真量取值**为准，不能直接套公式（对比见图 3 右）。

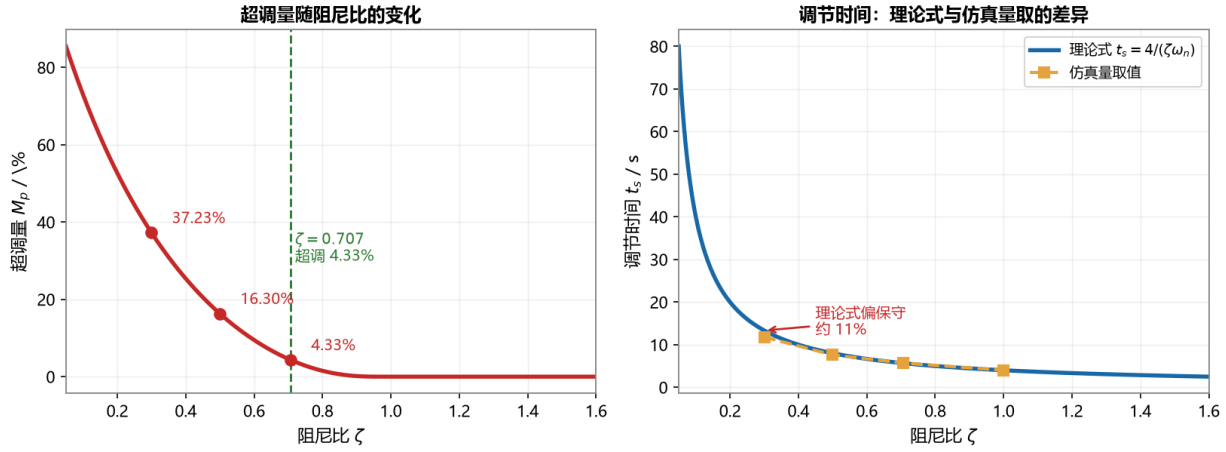


图 3　超调量与调节时间随阻尼比的变化；右图给出理论式与仿真量取的差异

结论：复现成功，模型与指标计算均可信。$\zeta \approx 0.707$ 时超调仅 4.33%，是超调与快速性的常用折中——这一结论将作为后续 PID 参数整定的定性依据。

5 阶段性收获

5.1 认知上的变化

我原以为控制算法是「选一个更好的算法就能解决问题」，读完这批文献后改变了看法：**控制效果的瓶颈往往不在算法，而在对控制通道的了解程度**。Vignon 的综述里提到，很多 DRL 控制研究之所以能在论文里取得好效果，是因为它们有廉价的仿真环境可以无限交互；而我们的散热片一旦涉及真实热惯性、流固耦合与传感器噪声，仿真与实物的差距就会成为主要误差源。

这个认识直接导致我把本阶段的重点从「学习更复杂的算法」转为「先把控制通道走通」——先把泵、水阀、散热片这三者的关系测清楚，再谈用不用智能算法。组长后来要求做控制实验，与这个判断是一致的。

5.2 尚存的疑问

1. 组长提出未来要加入**水阀**，那么未来就会出现「泵 + 阀」两个执行器共同决定流速的局面。两个执行器之间会不会相互耦合（比如关小阀门后泵的扬程发生变化）？如果耦合明显，就不能把二者当作独立变量处理。
2. 液冷回路的大热惯性到底有多大？仿真里用的一阶模型时间常数是设定的，**没有实测依据**。如果实测惯性远大于设定值，现有整套参数都要重来。
3. 传感器只有离散测点，而控制要稳的是芯片最高温度。**用测点温度代表最高温，误差有多大？**这决定了控制目标的定义方式。

6 下月计划

表 4 下月工作计划

事项	预期产出	时间
向组长确认控制实验的边界条件（现有执行器、可测量、不可控量）	实验变量清单	第 1 周
设计执行器特性与散热片特性的辨识方案	辨识实验方案	第 1–2 周
用现有仿真环境做辨识方法的预演（验证方法可行）	预演结果	第 2–3 周
整理控制部分已有代码与方法说明	可复现代码 + 方法文档	第 4 周

参考文献

[1] MNIH V, KAVUKCUOGLU K, SILVER D, et al. Human-level control through deep reinforcement learning[J]. Nature, 2015, 518(7540): 529-533.

[2] SCHULMAN J, WOLSKI F, DHARIWAL P, et al. Proximal policy optimization algorithms[EB/OL]. (2017-08-28)[2026-03-21]. https://arxiv.org/abs/1707.06347.

[3] VIGNON C, RABAULT J, VINUESA R. Recent advances in applying deep reinforcement learning for flow control: Perspectives and future directions[J]. Physics of Fluids, 2023, 35(3): 031301.

[4] TAO F, ZHANG H, ZHANG C. Advancements and challenges of digital twins in industry[J]. Nature Computational Science, 2024, 4(3): 169-177.

[5] BRUNTON S L, KUTZ J N. Data-driven science and engineering: Machine learning, dynamical systems, and control[M]. 2nd ed. Cambridge: Cambridge University Press, 2022.